



**Università
degli Studi
di Ferrara**

Intelligenza Artificiale, Data Science e Big Data

Marco Perozzi

Metodi di Ottimizzazione Stocastici

Confronto tra Strategie di Scheduling del Learning Rate e Interazione con gli Ottimizzatori

10 Giugno 2026

Dipartimento di Ingegneria e di Matematica e Informatica

Abstract

Questo lavoro confronta sistematicamente cinque strategie di learning rate scheduling (Costante, Exponential Decay, Cosine Annealing, Cyclic e One-Cycle) in combinazione con due ottimizzatori (SGD e Adam) su due scenari di ottimizzazione di diversa complessità: un problema convesso di classificazione binaria (regressione logistica sul dataset Breast Cancer) e uno non convesso di classificazione multiclasse (perceptrone multistrato sul dataset MNIST). I risultati mostrano che nessuna configurazione domina in assoluto; si osserva, invece, una netta inversione di tendenza nelle performance a seconda della natura del problema. Nello specifico, SGD abbinato a scheduler ciclici eccelle nel contesto convesso, mentre Adam con decadimento esponenziale o a coseno risulta più efficace in quello non convesso. Lo studio basato su 200 esperimenti con 10 seed indipendenti, evidenzia l'importanza critica dell'interazione tra ottimizzatore e scheduler.

Abstract

Il presente lavoro propone un'analisi comparativa sistematica dell'interazione tra algoritmi di ottimizzazione e strategie di aggiornamento del *learning rate* in scenari a complessità topologica variabile. Nello specifico, lo studio valuta l'efficacia congiunta di due ottimizzatori (Stochastic Gradient Descent, SGD, e Adam) e cinque politiche di scheduling (Costante, Exponential Decay, Cosine Annealing, Cyclic e One-Cycle). La valutazione si basa su uno studio comparativo di 200 run indipendenti, equamente ripartite tra due contesti diversi: un problema convesso di classificazione binaria (regressione logistica sul dataset Breast Cancer) e un problema non convesso di classificazione multiclasse (perceptrone multistrato sul dataset MNIST). I risultati empirici dimostrano l'assenza di una configurazione universalmente ottimale, evidenziando una netta divergenza dei risultati strettamente dipendente dalla geometria della funzione obiettivo. Nello scenario convesso, SGD abbinato a policy cicliche non monotone mostra una convergenza superiore. Al contrario, nello spazio non convesso, l'ottimizzazione adattiva (Adam) combinata con decadimenti monotoni (Esponenziale o a Coseno) risulta più efficace. Lo studio attesta formalmente come l'interazione tra le caratteristiche intrinseche dell'ottimizzatore e la politica di scheduling del *learning rate* sia il fattore critico per la massimizzazione delle performance.

Indice

1	Introduzione	1
1.1	Strategie di Learning Rate Scheduling	1
1.1.1	Learning Rate Costante (None)	1
1.1.2	Exponential Decay	1
1.1.3	Cosine Annealing	1
1.1.4	Cyclical Learning Rate (CLR)	2
1.1.5	One-Cycle Policy	2
1.2	Ottimizzatori	2
1.2.1	Stochastic Gradient Descent (SGD)	2
1.2.2	Adaptive Moment Estimation (Adam)	2
2	Metodologia Sperimentale	3
2.1	Setup Sperimentale	3
2.2	Metriche di Valutazione	3
2.3	Ottimo Empirico e Soglia di Convergenza	4
3	Risultati	5
3.1	Problema Convesso	5
3.1.1	Analisi della Convergenza	5
3.1.2	Analisi della Stabilità	7
3.2	Problema Non Convesso	8
3.2.1	Analisi della Convergenza	8
3.2.2	Analisi della Stabilità	10
4	Discussione e Conclusioni	12
4.1	Interazione Ottimizzatore-Scheduler	12
4.2	Conclusioni	13
	Bibliografia	13

Capitolo 1

Introduzione

L'addestramento di modelli di machine learning si configura come la minimizzazione di una funzione di costo $L(\theta)$ su $\theta \in \mathbb{R}^d$ tramite approssimazione stocastica su minibatch. In questo processo, il tasso di apprendimento (*learning rate*, η) rappresenta l'iperparametro critico che governa l'ampiezza dei passi di aggiornamento e, di conseguenza, la stabilità e la velocità della convergenza.

Nella pratica corrente, l'efficacia dell'addestramento è determinata dall'interazione tra l'ottimizzatore scelto e la strategia di variazione dinamica del passo nel tempo (*scheduler*). L'obiettivo di questo studio è condurre un'analisi sistematica sulla sinergia tra due ottimizzatori di riferimento (SGD e Adam) e cinque diverse politiche di scheduling. Il confronto viene declinato su due topologie di ottimizzazione opposte: un problema convesso e uno non convesso, al fine di evidenziare come l'efficacia algoritmica non sia assoluta, ma strettamente vincolata alla natura geometrica della funzione obiettivo.

1.1 Strategie di Learning Rate Scheduling

La modulazione del passo influisce direttamente sulla convergenza. Di seguito vengono descritte le cinque strategie analizzate in questo studio.

1.1.1 Learning Rate Costante (None)

La configurazione di riferimento non prevede alcuna variazione dinamica del passo, mantenendo il valore iniziale inalterato per l'intera durata dell'addestramento:

$$\eta_k = \eta_0 \quad (1.1)$$

1.1.2 Exponential Decay

Questa strategia introduce una riduzione geometrica del passo a ogni epoca, controllata da un fattore di decadimento γ :

$$\eta_k = \eta_0 \gamma^k \quad \text{con } \gamma < 1 \quad (1.2)$$

1.1.3 Cosine Annealing

Introdotta da Loshchilov e Hutter (2017), questo scheduler modula il learning rate seguendo una traiettoria cosinusoidale, decrescendo progressivamente da un valore massimo a uno minimo su un budget di epoche pari a $T_{\max}$:

$$\eta_k = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \left(\frac{k\pi}{T_{\max}} \right) \right) \quad (1.3)$$

1.1.4 Cyclical Learning Rate (CLR)

La strategia ciclica (Smith 2017) fa variare il passo in modo alternato tra due estremi fissati ($\eta_{\min}$ e $\eta_{\max}$) con una frequenza determinata dalla dimensione della semionda (S). La formulazione generale prevede:

$$\begin{aligned}\eta_k &= \eta_{\min} + (\eta_{\max} - \eta_{\min}) \cdot \max(0, 1 - x_k) \cdot \gamma(c_k, k) \\ c_k &= \left\lfloor \frac{k}{2S} \right\rfloor, \quad x_k = \left\lfloor \frac{k}{S} - 2c_k - 1 \right\rfloor\end{aligned}\tag{1.4}$$

dove la funzione di smorzamento $\gamma(c_k, k)$ definisce la variante specifica dello scheduler:

$$\gamma(c_k, k) = \begin{cases} 1 & \text{per la variante } \textit{triangular} \\ \frac{1}{2^{c_k}} & \text{per la variante } \textit{triangular2} \end{cases}\tag{1.5}$$

Ai fini del presente studio, viene selezionata la variante *triangular2*, la quale dimezza sistematicamente l'ampiezza massima dell'oscillazione al completamento di ogni ciclo.

1.1.5 One-Cycle Policy

Evoluzione del CLR proposta da Smith e Topin (2018), la One-Cycle Policy è strutturata in tre fasi distinte distribuite su un numero totale di epoche K : un *warm-up* fino a $\eta_{\max}$, un *cool-down* simmetrico fino a $\eta_{\min}$, e una fase di decadimento finale verso un valore asintotico inferiore η_{end} . Negli esperimenti, le transizioni seguono una strategia di attenuazione cosinusoidale (*anneal strategy*) definita da:

$$\eta_k = \begin{cases} \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 - \cos\left(\frac{\pi k}{S}\right)\right) & 0 \leq k \leq S \\ \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos\left(\frac{\pi(k-S)}{S}\right)\right) & S < k \leq 2S \\ \eta_{\text{end}} + \frac{1}{2}(\eta_{\min} - \eta_{\text{end}}) \left(1 + \cos\left(\frac{\pi(k-2S)}{K-2S}\right)\right) & 2S < k \leq K \end{cases}\tag{1.6}$$

1.2 Ottimizzatori

Vengono esaminate le due principali famiglie di algoritmi di ottimizzazione stocastica del primo ordine.

1.2.1 Stochastic Gradient Descent (SGD)

L'algoritmo SGD aggiorna i parametri del modello muovendosi nella direzione opposta a quella del gradiente stocastico, stimato su un sottoinsieme di dati (*minibatch*) $\mathcal{B}_k$:

$$\theta_k \leftarrow \theta_{k-1} - \eta g_k\tag{1.7}$$

dove $g_k = |\mathcal{B}_k|^{-1} \sum_{i \in \mathcal{B}_k} \nabla \ell(f(x_i; \theta_{k-1}), y_i)$ (Goodfellow et al. 2016). Sotto l'ipotesi di un tasso di apprendimento η costante, l'SGD garantisce la convergenza esclusivamente entro un intorno dell'ottimo la cui ampiezza risulta proporzionale al passo stesso (Robbins e Monro 1951).

1.2.2 Adaptive Moment Estimation (Adam)

Sviluppato da Kingma e Ba (2017), Adam combina i punti di forza del momento stocastico e del controllo adattivo del passo. L'algoritmo calcola dinamicamente un tasso di apprendimento specifico per ciascun parametro, riscalandolo il gradiente in base alla sua variabilità recente:

$$\theta_k \leftarrow \theta_{k-1} - \frac{\eta}{\sqrt{\hat{v}_k} + \epsilon} \hat{m}_k\tag{1.8}$$

dove $\hat{m}_k$ e $\hat{v}_k$ rappresentano rispettivamente le stime della direzione e dell'intensità dei gradienti precedenti. Questa normalizzazione locale attenua la sensibilità dell'algoritmo rispetto alla scelta del learning rate globale η , accelerando la convergenza in presenza di curve irregolari o punti di sella.

Capitolo 2

Metodologia Sperimentale

2.1 Setup Sperimentale

Il confronto avviene su due diversi problemi: il problema *convesso* utilizza la **regressione logistica** per una task di *classificazione binaria* sul dataset **Breast Cancer Wisconsin** (569 campioni, 30 features); il problema *non convesso* adotta un **multilayer perceptron** (MLP) con struttura $784 \rightarrow 256 \rightarrow 128 \rightarrow 10$, attivazioni ReLU e Dropout ($p = 0.3$), per una *classificazione multiclasse* ($C = 10$) sul dataset **MNIST** (70.000 immagini 28×28). Il comportamento di algoritmi e scheduler viene valutato principalmente attraverso l'andamento della funzione di costo (*Cross Entropy Loss*):

$$L(\theta) = -\frac{1}{N} \sum_{i=1}^N \sum_{c=1}^C y_{i,c} \log(p_{i,c}) \quad (2.1)$$

Configurazione degli Iperparametri e Inizializzazione Dinamica

Tabella 2.1: Configurazione degli iperparametri di addestramento.

Iperparametro	SGD	Adam
Learning Rate Iniziale (η_0)	0.01	0.001
Epoche di Training	100	100
Dimensione del Batch (<i>Batch Size</i>)	128	128
Numero di Seed Indipendenti	10	10

I parametri specifici degli scheduler vengono iniettati in modo dinamico all'avvio del training:

- **Massimi** ($\eta_{\max}$): Nelle strategie cicliche il passo massimo è fissato a $\eta_{\max} = 10 \times \eta_0$.
- **Sincronizzazione Temporale**: La durata delle fasi è calcolata a runtime in base alle iterazioni per epoca (*steps_per_epoch*):
 - Cosine Annealing: periodo di attenuazione allineato alle epoche totali ($T_{\max} = \text{epochs}$).
 - Cyclical LR: semionda di salita del profilo triangolare pari a $2 \times \text{steps_per_epoch}$.
 - One-Cycle: intero ciclo tarato sui passi totali ($\text{epochs} \times \text{steps_per_epoch}$).
- **Exponential Decay**: Il tasso γ è calcolato affinché garantisca una riduzione fissa di $10\times$ il valore iniziale all'ultima epoca.

2.2 Metriche di Valutazione

Le seguenti metriche quantificano velocità della convergenza, stabilità del training e capacità di generalizzazione.

- **Epochs to Target (EtT) e Tasso di Convergenza:** $K_{\text{ett}} = \min\{k : L_k \leq L_{\text{target}}\}$. Misura il numero di epoche strettamente necessarie per intersecare la soglia di tolleranza predefinita (vedi Sezione 2.3). Se la soglia non viene raggiunta entro il budget di epoche, la run viene conteggiata come fallimento nel tasso di convergenza $r_{\text{conv}} \in [0, 1]$.
- **Area Under Loss (AUL):** $\text{AUL} = \int_0^K L_k dk$. Calcolata per integrazione trapezoidale sull'intera traiettoria della loss, quantifica la rapidità della fase di discesa. Valori inferiori indicano una riduzione più rapida della funzione di costo.
- **Suboptimality Gap:** $\Delta(K) = L_K - L^*$. Misura l'errore residuo finale rispetto all'ottimo empirico L^* .
- **Coefficiente di Variazione della Loss (CV):** $\text{CV} = \frac{\sigma_L}{\mu_L}$ valutato sulla porzione di curva $k \geq t_0$, al netto della fase di *warm-up* ($t_0 = 5$ epochs). Permette di valutare se la traiettoria di minimizzazione è fluida e monotona oppure se subisce oscillazioni.
- **Statistiche della Norma del Gradiente (μ_G, σ_G):** $\mu_G = \mathbb{E}[\|\nabla_{\theta} L\|_2]$ e σ_G (deviazione standard *pooled* intra-run) quantificano rispettivamente magnitudo media e variabilità della norma del gradiente. Rappresenta una diagnostica geometrica per la stabilità del training: valori elevati identificano regimi esplosivi e caotici nello spazio dei parametri.
- **Capacità di Generalizzazione (Test Loss e Test Accuracy):** Valutate sul set di hold-out (20% split) al termine dell'addestramento. Misurano la capacità del modello di generalizzare a dati non visti.

2.3 Ottimo Empirico e Soglia di Convergenza

Per quantificare l'efficienza degli algoritmi, viene stimato l'ottimo empirico L^* di ciascun problema. A partire dalle configurazioni esaminate, quella che ha ottenuto la loss minore viene sottoposta a un addestramento esteso oltre il budget di epoche standard, fino a isolare il limite asintotico della funzione di costo. Tale valore definisce L^* , utilizzato come baseline per calcolare la soglia di convergenza L_{target} , intesa come il raggiungimento del 95% della discesa potenziale rispetto alla loss iniziale L_0 :

$$L_{\text{target}} = L^* + \epsilon(L_0 - L^*) \quad \text{con} \quad \epsilon = 0.05 \quad (2.2)$$

Capitolo 3

Risultati

In questo capitolo vengono presentati i risultati ottenuti dall'esperimento per i due problemi: convesso e non convesso. I dati sono presentati divisi per le caratteristiche che si volevano analizzare: velocità di convergenza, stabilità dell'addestramento e performance di generalizzazione

3.1 Problema Convesso

3.1.1 Analisi della Convergenza

SGD + Cyclic e SGD + One-Cycle convergono con netto distacco rispetto alle altre configurazioni, sia per il valore minimo di loss raggiunto (Suboptimality Gap rispettivamente 0.01305 e 0.00409) sia per la velocità di convergenza (EtT 5.7 e 11.9). Come evidenziato dal grafico in Figura 3.1, gli scheduler ciclici combinati con SGD mostrano una discesa estremamente ripida nelle prime epoche di training, per poi stabilizzarsi in prossimità del minimo per il resto dell'addestramento. Tra le configurazioni basate su Adam, solo Adam + One-Cycle riesce a raggiungere la soglia di convergenza predefinita.

SGD + Cyclic e SGD + One-Cycle presentano la massima concentrazione intorno ai valori mediani (Figura 3.2), con una variabilità contenuta (deviazione standard = 1.7 e 3.2), confermando la netta superiorità di queste configurazioni. Adam + One-Cycle mostra una dispersione molto elevata con EtT minimo 30 e massimo 90 epoche.

Tabella 3.1: Metriche di convergenza — Problema Convesso

Configurazione	AUL	SuboptGap	EtT	ConvRate	TestLoss	TestAcc (%)
SGD + None	19.37	0.06990	—	0.0	0.12466	96.32
SGD + Exponential	23.83	0.12977	—	0.0	0.19242	94.65
SGD + Cosine	20.40	0.10064	—	0.0	0.15150	95.09
SGD + Cyclic	7.12	<u>0.01305</u>	5.7 ± 1.7	1.0	0.08345	<u>97.46</u>
SGD + One-Cycle	<u>7.88</u>	0.00409	<u>11.9 ± 3.2</u>	1.0	0.09478	<u>97.46</u>
Adam + None	28.67	0.08485	—	0.0	0.13092	96.67
Adam + Exponential	27.78	0.14484	—	0.0	0.19935	94.04
Adam + Cosine	33.88	0.16350	—	0.0	0.20453	93.42
Adam + Cyclic	16.12	0.05320	71.0 ± 11.3	0.3	0.09954	97.54
Adam + One-Cycle	20.26	0.03152	47.6 ± 15.8	1.0	<u>0.09223</u>	97.02

La rapidità di discesa di SGD + Cyclic trova riscontro anche nei valori dell'area sotto la curva della loss (Tabella 3.1). SGD + One-Cycle registra il suboptimality gap inferiore, evidenziando la capacità dell'algoritmo di approssimare l'ottimo nelle fasi avanzate di training grazie alla terza fase del ciclo (decadimento cosinusoidale). Le policy a decadimento e a learning rate costante non raggiungono la soglia di convergenza con nessuno dei due ottimizzatori, dimostrandosi inadeguate per la geometria di questo specifico compito convesso, a parità di iperparametri.




Figura 3.1: Confronto globale delle curve di loss — Problema convesso.




Figura 3.2: Distribuzione delle epoche di convergenza — Problema convesso.

Generalizzazione. Adam + Cyclic raggiunge la migliore accuratezza di test, seguito da SGD + Cyclic e SGD + One-Cycle. Le configurazioni Adam con scheduler a decadimento raggiungono le accuratezze più basse. In questo scenario le configurazioni che convergono hanno un'accuratezza leggermente maggiore, probabilmente correlato a una maggior riduzione della loss. Comunque, la convergenza formale non è un prerequisito per la generalizzazione.

3.1.2 Analisi della Stabilità




Figura 3.3: Varianza tra seed — Problema convesso.

La differenza tra ottimizzatori emerge di più nella varianza tra seed (Figura 3.3): le configurazioni SGD sono più consistenti, mentre Adam produce una variabilità maggiore con tutti gli scheduler.

SGD + Cyclic presenta la dinamica di ottimizzazione più regolare eccellendo in tutte le metriche (Tabella 3.2), riuscendo comunque a mantenere una traiettoria stabile nonostante la variazione periodica del learning rate. La magnitudo media del gradiente riscontra i valori minimi nelle configurazioni SGD convergenti e il picco massimo in Adam + Cosine, che infatti è la peggiore in termini di loss raggiunta. L'elevato coefficiente di variazione di Adam + One-Cycle ($CV = 1.16$) riflette un'alta instabilità delle traiettorie, caratterizzata da ampie oscillazioni nella loss e nella norma del gradiente. Come evidenziato in Figura 3.3, tale comportamento è indotto dall'interazione tra la fase di *warm-up* e l'adattività per-componente, che determina una decrescita inizialmente lenta della loss, dovuta a valori del LR superiori alla media, seguita poi da una rapida discesa nelle epoche successive (*cool-down*).

Tabella 3.2: Metriche di stabilità — Problema Convesso

Configurazione	CV	μ_G	σ_G
SGD + None	0.3900	0.3357	0.3775
SGD + Exponential	0.2566	0.4068	0.3001
SGD + Cosine	0.3284	0.3684	0.3704
SGD + Cyclic	0.1097	0.0860	0.2047
SGD + One-Cycle	0.3545	0.1095	0.3035
Adam + None	0.5561	0.5587	0.5532
Adam + Exponential	0.3123	0.5476	0.3456
Adam + Cosine	0.4580	0.6779	0.5165
Adam + Cyclic	0.3038	0.2594	0.3402
Adam + One-Cycle	1.1647	0.3765	0.7036

3.2 Problema Non Convesso

3.2.1 Analisi della Convergenza

Su MNIST (Figura 3.4), la topologia del problema determina una netta inversione di tendenza: Adam eccelle con i decadimenti monotoni (Exponential e Cosine), raggiungendo la soglia di convergenza in circa 20 epoche, e converge con efficacia decrescente anche con Cyclic (30 epoche) e Costante (40 epoche). In questo quadro, l'unica eccezione è rappresentata da One-Cycle, che con Adam non raggiunge la convergenza.

Al contrario, SGD mostra una rigida dipendenza dallo scheduler, fallendo sistematicamente la convergenza nelle varianti statiche o a decadimento continuo. L'unica configurazione competitiva rimane SGD + Cyclic, la quale assicura una discesa iniziale rapida, raggiungendo la soglia in 17.2 epoche, ma con una saturazione delle prestazioni nel resto dell'addestramento.

SGD + Cyclic, Adam + Exponential e Adam + Cosine mostrano la dispersione cross-seed (IQR) minore (Figura 3.5). La bassa variabilità è confermata da una deviazione standard di EtT tra 0.9 e 1.3 per queste configurazioni.

Tabella 3.3: Metriche di convergenza — Problema Non Convesso

Configurazione	AUL	SuboptGap	EtT	ConvRate	TestLoss	TestAcc
SGD + None	12.52	0.05360	—	0.0	0.07553	97.81%
SGD + Exponential	15.75	0.10677	—	0.0	0.09521	97.14%
SGD + Cosine	13.90	0.08988	—	0.0	0.08778	97.35%
SGD + Cyclic	<u>2.77</u>	0.00786	17.2 ± 1.3	1.0	0.08910	98.27%
SGD + One-Cycle	5.14	0.00462	57.4 ± 2.0	1.0	0.10605	<u>98.37%</u>
Adam + None	3.76	0.01774	31.0 ± 2.1	1.0	0.10747	98.24%
Adam + Exponential	2.61	<u>0.00318</u>	<u>21.1 ± 0.9</u>	1.0	0.10360	<u>98.36%</u>
Adam + Cosine	<u>2.86</u>	0.00236	26.8 ± 1.2	1.0	0.10132	98.42%
Adam + Cyclic	4.98	0.02170	42.6 ± 3.2	1.0	0.11937	97.99%
Adam + One-Cycle	18.17	0.05147	—	0.0	0.26054	97.68%

Nello scenario non convesso, Adam + Exponential e SGD + Cyclic si contendono il primato nella rapidità di discesa lunga la funzione obiettivo: la prima supera la seconda in termini di area sotto la curva della loss (AUL), mentre l'ordine si inverte se si considera il numero di epoche per il raggiungimento de target (EtT). Questa complementarità evidenzia come entrambe le configurazioni eccellano (Tabella 3.3).

Generalizzazione. La migliore accuratezza su MNIST è di Adam + Cosine (98.42%), seguito da SGD + One-Cycle (98.37%) e Adam + Exponential (98.36%). Sono queste le tre configurazioni che scendono maggiormente lunga la funzione obiettivo e raggiungono i minori Gap di Subottimalità. Ciononostante le prime sette configurazioni si collocano entro 0.61 pp: il raggiungimento della soglia di convergenza non è un prerequisito per buone performance di generalizzazione.




Figura 3.4: Confronto globale delle curve di loss — Problema non convesso.




Figura 3.5: Distribuzione delle epoche di convergenza — Problema non convesso.

3.2.2 Analisi della Stabilità

La variabilità inter-seed è maggiore nella fase finale dell’addestramento, soprattutto con Adam, a differenza del caso convesso dove il fenomeno si concentrava nelle epoche iniziali. In controtendenza, SGD + Cosine e SGD + Exponential mostrano traiettorie molto stabili, con i valori di CV più bassi in assoluto (Figura 3.6).

Tuttavia, in un contesto non convesso, che è intrinsecamente caotico e ricco di minimi locali, la presenza di oscillazioni è del tutto normale per permettere un’efficace esplorazione dello spazio. Di conseguenza, le configurazioni che performano peggio risultano essere le più stabili proprio perché, non oscillando, rimangono precocemente bloccate in soluzioni sub-ottimali.




Figura 3.6: Varianza tra seed — Problema non convesso.

Adam + None e Adam + Cyclic hanno il gradiente più stabile nonostante CV moderati. SGD + Exponential mostra il CV più basso ma una magnitudo media elevata: passi ampi ma regolari. All’opposto, Adam + Cosine e Adam + Exponential hanno CV elevati con μ_G contenuta: la loss oscilla in un intorno ristretto senza divergere, comportamento tipico di ottimizzatori adattivi vicini al minimo (Tabella 3.4).

Adam + One-Cycle registra la dinamica più instabile e la magnitudo media del gradiente più elevata in assoluto. L’andamento non monotono della loss (Figura 3.7) rivela una traiettoria apparentemente anomala, caratterizzata da un iniziale crollo seguito da un marcato incremento dell’errore tra le epoche 10 e 30. Questa evoluzione risulta in realtà strettamente vincolata alla dinamica della One-Cycle Policy. Il fenomeno è scaturito dalla fase di *warm-up*: l’aumento di un ordine di grandezza del learning rate destabilizza temporaneamente Adam, forzando l’ottimizzatore a compiere passi troppo ampi che fanno risalire la loss. Solo con il passaggio alla fase di *cool-down* (dall’epoca 30 in poi), la progressiva riduzione del passo permette all’algoritmo di correggere la traiettoria, che comunque è già stata compromessa.

Tabella 3.4: Metriche di stabilità — Problema Non Convesso

Configurazione	CV	μ_G	σ_G
SGD + None	0.4987	1.0850	0.2240
SGD + Exponential	0.2961	1.1592	0.1940
SGD + Cosine	0.3695	1.1195	0.2077
SGD + Cyclic	0.7206	0.4865	0.1710
SGD + One-Cycle	0.7013	0.5609	0.2913
Adam + None	0.4926	0.5268	0.1563
Adam + Exponential	0.9598	0.3934	0.2223
Adam + Cosine	0.9370	0.3938	0.2377
Adam + Cyclic	0.6733	0.4847	0.1705
Adam + One-Cycle	0.5349	1.0696	0.3666




Figura 3.7: Loss e LR in Adam + One-Cycle — Problema non convesso.

Capitolo 4

Discussione e Conclusioni

4.1 Interazione Ottimizzatore-Scheduler

L'analisi comparativa dei risultati evidenzia un comportamento speculare nell'interazione tra ottimizzatori e strategie di scheduling, confermando come l'efficacia di una combinazione sia strettamente subordinata alla topologia del problema.

Scenario Convesso. Nella regressione logistica, i risultati confermano l'efficacia di **SGD**, a considerazione che sia abbinato a scheduler ciclici, quindi non monotoni (Wilson et al. 2017). Infatti, le configurazioni dominanti sono **SGD + Cyclic** e **SGD + One-Cycle** che raggiungono la soglia in sole 5.7 e 11.9 epoche, riducono maggiormente il divario con L^* e presentano un'elevata stabilità della Loss e della Norma del Gradiente. Al contrario, i decadimenti decrescenti (Cosine, Exponential) non permettono la convergenza di SGD in nessuna run, confermando il rischio di arresto prematuro causato da una riduzione troppo rapida del learning rate su pendenze regolari (Smith 2017).

I vantaggi delle politiche cicliche si estendono anche ad Adam, che registra la sua performance migliore proprio con Cyclical. Questo dimostra l'utilità di mantenere un passo variabile nei problemi convessi, in linea con Defazio et al. (2024), i quali evidenziano come le schedulazioni non monotone superino i classici decadimenti lineari su problemi convessi.

Scenario Non Convesso. Con la rete neurale la gerarchia si inverte. Le configurazioni predilette risultano **Adam + Exponential** e **Adam + Cosine**, che raggiungono la convergenza in 21.1 e 26.8 epoche. Questi dati supportano le tesi di Dereich et al. (2024) sull'utilità di combinare l'adattatività per-componente con una riduzione globale e continua del passo in spazi complessi. Al contrario, SGD fatica sulla topologia irregolare di MNIST. Privo di normalizzazione locale, rallenta o fallisce nella maggior parte dei test. L'unica eccezione di estrema rilevanza è **SGD + Cyclic**: sfruttando le oscillazioni del tasso di apprendimento per evadere dai punti di sella (Dauphin et al. 2014; Smith 2017), questa configurazione non solo converge, ma risulta la più veloce in assoluto (17.2 epoche).

Le tre configurazioni migliori (Adam + Exponential, Adam + Cosine e SGD + Cyclic) si alternano nelle prime posizioni delle principali metriche (EtT, AUL, Accuratezza). L'assenza di un dominatore assoluto deriva dalla natura non convessa della funzione obiettivo: la complessa topologia e la presenza di minimi locali causano oscillazioni fisiologiche nei risultati, rendendo di fatto le metriche di stabilità molto meno rilevanti e informative rispetto a quanto avviene negli scenari convessi.

L'indicatore che elegge come migliori le due strategie monotone di Adam è il *Suboptimality Gap*. Difatti i valori ottenuti nettamente migliori (0.00318 e 0.00236) rispetto allo scheduler ciclico di SGD (0.00786), dimostrando che l'adattatività di Adam permette di effettuare una discesa più profonda e precisa verso il minimo della funzione di Loss in problemi di questo tipo. In generale, Adam si conferma più stabile al variare dello scheduler (Kingma e Ba 2017).

4.2 Conclusioni

Alla luce dei risultati sperimentali e delle dinamiche osservate, è possibile delineare le seguenti conclusioni:

- La combinazione tra ottimizzatore e scheduler determina l'esito della convergenza in misura maggiore rispetto alle singole componenti, ma tale sinergia è strettamente subordinata alla geometria del problema (convesso o non convesso).
- L'interazione ottimizzatore-scheduler non è speculare. La validità di una politica non è trasferibile tra ottimizzatori: i decadimenti monotoni (Exponential, Cosine) ottimizzano le prestazioni di Adam nei problemi complessi, ma causano il fallimento sistematico di SGD.
- Le prestazioni di SGD dipendono in modo critico dall'impiego di scheduler non monotoni (Cyclic, One-Cycle). Le oscillazioni del passo sono il requisito fondamentale per evitare l'arresto prematuro su pendenze regolari e per evadere dai punti di sella in spazi irregolari.
- Grazie all'adattatività per-componente, Adam risulta intrinsecamente più resiliente alle variazioni di scheduling nei contesti non convessi.
- Negli scenari non convessi, le metriche di stabilità perdono rilevanza analitica. Le oscillazioni fisiologiche non indicano inefficienza algoritmica, ma costituiscono un meccanismo esplorativo necessario per navigare la presenza di minimi locali.
- La convergenza formale in fase di addestramento è solo parzialmente correlata alla capacità di generalizzazione del modello. Configurazioni che falliscono la convergenza stretta possono comunque produrre prestazioni altamente competitive in fase di test.

Bibliografia

- Dauphin, Yann N, Pascanu, Razvan, Gulcehre, Caglar, Cho, Kyunghyun, Ganguli, Surya e Bengio, Yoshua (2014). «Identifying and Attacking the Saddle Point Problem in High-Dimensional Non-Convex Optimization». In: *Advances in Neural Information Processing Systems*. Vol. 27. Curran Associates, Inc. (Visitato il 06/06/2026).
- Defazio, Aaron, Cutkosky, Ashok, Mehta, Harsh e Mishchenko, Konstantin (29 ott. 2024). *Optimal Linear Decay Learning Rate Schedules and Further Refinements*. DOI: 10.48550/arXiv.2310.07831. (Visitato il 31/05/2026).
- Dereich, Steffen, Jentzen, Arnulf e Riekert, Adrian (20 giu. 2024). *Learning Rate Adaptive Stochastic Gradient Descent Optimization Methods: Numerical Simulations for Deep Learning Methods for Partial Differential Equations and Convergence Analyses*. DOI: 10.48550/arXiv.2406.14340. (Visitato il 31/05/2026).
- Goodfellow, Ian, Bengio, Yoshua e Courville, Aaron (2016). *Deep Learning*. Adaptive Computation and Machine Learning. Cambridge, Massachusetts: The MIT Press. 775 pp.
- Kingma, Diederik P. e Ba, Jimmy (30 gen. 2017). *Adam: A Method for Stochastic Optimization*. DOI: 10.48550/arXiv.1412.6980. (Visitato il 25/05/2026).
- Loshchilov, Ilya e Hutter, Frank (3 mag. 2017). *SGDR: Stochastic Gradient Descent with Warm Restarts*. DOI: 10.48550/arXiv.1608.03983. (Visitato il 25/05/2026).
- Robbins, Herbert e Monro, Sutton (1951). «A Stochastic Approximation Method». In: *The Annals of Mathematical Statistics* 22.3, pp. 400–407. (Visitato il 25/05/2026).
- Smith, Leslie N. (mar. 2017). «Cyclical Learning Rates for Training Neural Networks». In: 2017 IEEE Winter Conference on Applications of Computer Vision (WACV), pp. 464–472. DOI: 10.1109/WACV.2017.58. (Visitato il 25/05/2026).
- Smith, Leslie N. e Topin, Nicholay (17 mag. 2018). *Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates*. DOI: 10.48550/arXiv.1708.07120. (Visitato il 25/05/2026).
- Wilson, Ashia, Roelofs, Rebecca, Stern, Mitchell, Srebro, Nati e Recht, Benjamin (2017). «The Marginal Value of Adaptive Gradient Methods in Machine Learning». In: *Advances in Neural Information Processing Systems*. Vol. 30. Curran Associates, Inc. (Visitato il 06/06/2026).